ПРАКТИЧНА РОБОТА № 9-10

Неперервні випадкові величини, закони розподілу та статистичне моделювання в аналізі продуктивності ПЗ

Мета: засвоїти практичні навички моделювання неперервних випадкових величин (НВВ), вивчити методи побудови та графічного аналізу функції розподілу **F(x)** і щільності ймовірності **f(x)**; навчитися обчислювати точкові статистичні характеристики (**M[X], D[X], σ[X]**, квантилі/перцентилі p50, p90, p95, p99) та емпірично перевіряти Закон великих чисел (ЗВЧ) і Центральну граничну теорему (ЦГТ) мовами програмування високого рівня.

Компетентності, що формуються:

– розуміння відмінностей між дискретними та неперервними випадковими величинами, властивостей **F(x)** та **f(x)**;

– вміння обчислювати математичне сподівання, дисперсію та ймовірності потрапляння НВВ в інтервал для рівномірного, показникового та нормального законів розподілу;

– вміння проводити перцентильний аналіз затримок (Latency Tail Analysis) програмних систем та емпірично досліджувати ЦГТ методом Монте-Карло.

Прив’язка блоків до теми «Неперервні випадкові величини»

Блок	Теоретична основа	Тема
Блок 1 — Перевірка ЦГТ	Центральна гранична теорема, збіжність суми незалежних НВВ до нормального розподілу $N(\mu,\sigma^2)$	Лекція 6
Блок 2 — Аналіз НВВ за варіантом	Щільність f(x), функція F(x), M[X], D[X], σ[X]; закони U(a,b), Exp(λ), $N(\mu,\sigma^2)$	Лекція 6
Блок 3 — Перцентильний аналіз затримок (Latency Tail)	Показниковий та нормальний закони, квантилі, перцентилі p50, p90, p95, p99	Лекція 6
Блок 4 — Професійні комплексні задачі	Моделювання навантаження CPU/RAM, часу MTBF, трафіку та затримок	Лекція 6

Короткі теоретичні відомості

1. Функція розподілу та щільність ймовірності НВВ

Функція розподілу (CDF): $F(x) = P(X < x)$. Властивості: $0 \le F(x) \le 1$, неспадна, $F(-\infty) = 0$, $F(+\infty) = 1$.

Щільність ймовірності (PDF): $f(x) = F'(x)$. Властивості: $f(x) \ge 0$ та умова нормування:

$$\int_{-\infty}^{+\infty} f(x)\,dx = 1, \qquad P(a \le X \le b) = \int_a^b f(x)\,dx = F(b) - F(a)$$

2. Числові характеристики НВВ

$$M[X] = \int x \cdot f(x)\,dx, \quad D[X] = \int x^2 \cdot f(x)\,dx - (M[X])^2, \quad \sigma[X] = \sqrt{D[X]}$$

3. Основні закони розподілу у програмних системах

Рівномірний U(a, b):

$$f(x) = 1/(b-a) \text{ на } [a,b]; \quad M[X] = (a+b)/2; \quad D[X] = (b-a)^2/12$$

Показниковий Exp(λ) (час між подіями**):**

$$f(x) = \lambda e^{-\lambda x} \ (x \ge 0); \quad F(x) = 1 - e^{-\lambda x}; \quad M[X] = 1/\lambda; \quad D[X] = 1/\lambda^2$$

Нормальний N(μ, σ²):

$$f(x) = (1/\sigma\sqrt{2\pi}) \cdot e^{\wedge}(-(x-\mu)^2/2\sigma^2); \quad M[X] = \mu; \quad D[X] = \sigma^2$$

Правило трьох сигм: $P(|X - \mu| \le 3\sigma) = 2\Phi(3) - 1 \approx 0{,}9973$.

4. Центральна гранична теорема (ЦГТ)

Якщо $X_1, X_2, \ldots, X_k$ — незалежні однаково розподілені величини з $M[X_i] = \mu$, $D[X_i] = \sigma^2$, то при $k \to \infty$ розподіл суми $S_k = \Sigma X_i$ наближається до $N(k\mu, k\sigma^2)$, а стандартизована сума:

$$Z_k = (S_k - k\mu) / (\sigma\sqrt{k}) \ \to \ N(0, 1)$$

Структура практичного завдання

Робота складається з чотирьох обов'язкових блоків.

Блок 1. Програмна перевірка Центральної Граничної Теореми

Просимулювати суму $S_k = \Sigma\, X_i$ незалежних величин $X_i \sim U(0, 1)$. Для них $\mu = 0{,}5$, $\sigma^2 = 1/12 \approx 0{,}08333$; для суми $M[S_k] = 0{,}5k$, $D[S_k] = k/12$. Стандартизована величина $Z_k = (S_k - 0{,}5k)/\sqrt{(k/12)}$.

Завдання:

1. Згенерувати N = 100 000 значень Z_k для $k \in \{1, 2, 5, 12, 30\}$.

2. Для кожного k побудувати нормовану гістограму щільності та накласти теоретичну щільність стандартного нормального розподілу $\varphi(z) = (1/\sqrt{2\pi})\cdot e^{-z^2/2}$.

3. Обчислити вибіркові $M[Z_k]$ (≈ 0), $D[Z_k]$ (≈ 1), коефіцієнти асиметрії (Skewness) та ексцесу (Kurtosis); показати їх прямування до 0 при зростанні k.

Блок 2. Аналіз неперервної випадкової величини за варіантом

Реалізувати симуляційну модель за своїм варіантом. Згенерувати вибірку **N = 100 000**, обчислити теоретичні та вибіркові характеристики (**M[X], D[X], σ[X]**, ймовірність потрапляння в інтервал) і порівняти.

Вибір варіанта: **Variant = (Nстудента mod 6) + 1**.

Варіанти завдань до Блоку 2

Варіант 1. Затримка відгуку API (U). X ~ U(10, 50) мс. Теорія: f=0,025, M=30 мс, D≈133,33, σ≈11,547, P(20≤X≤40)=0,5. Побудувати гістограму й ECDF, порівняти з теорією.

Варіант 2. MTBF сервера (Exp). X ~ Exp(0,05) 1/год. Теорія: M=20 год, D=400, σ=20, $P(X>30)=e^{-1\cdot5}\approx0{,}2231$. Оцінити вибіркові характеристики та P(X>30), побудувати щільність.

Варіант 3. Використання RAM (N). X ~ N(512, 64^2) МБ. Теорія: M=512, σ=64, D=4096, P(X>640)=P(Z>2)=0,0228. Згенерувати через numpy.random.normal(512,64), знайти частку >640 МБ.

Варіант 4. Пропускна здатність (N). X ~ N(100, 15^2) Мбіт/с. Теорія: M=100, σ=15, P(85≤X≤115)=2Φ(1)−1≈0,6827, 3σ: P(55≤X≤145)≈0,9973. Побудувати гістограму з межами μ±3σ.

Варіант 5. Час транзакції БД (Exp). X ~ Exp(2,0) с. Теорія: M=0,5, D=0,25, σ=0,5, $P(X\le0{,}2)=1-e^{-0\cdot4}\approx0{,}3297$. Побудувати ECDF і порівняти з $F(x)=1-e^{-2x}$.

Варіант 6. Розмір Ethernet-пакета (U). X ~ U(64, 1500) байт. Теорія: M=782, D≈171841,33, σ≈414,54, P(X>1000)=500/1436≈0,3482. Обчислити вибіркові середнє, дисперсію, P(X>1000).

Блок 3. Перцентильний аналіз затримок ПЗ — Latency Tail Analysis

Затримка моделюється як суміш: 90% запитів штатні (**$X_1 \sim N(20, 4^2)$** мс), 10% — складні/GC (**$X_2 \sim Exp(0{,}01)$**, M[X_2]=100 мс).

Завдання:

1. Змоделювати N = 100 000 затримок: з імовірністю 0,90 — значення з N(20,16); з 0,10 — з Exp(0,01).
2. Обчислити вибіркове середнє, σ, медіану p50 та перцентилі p90, p95, p99 (numpy.percentile).
3. Побудувати гістограму щільності та графік F(x), позначивши перцентилі вертикальними пунктирними лініями.

Блок 4. Професійні комплексні задачі

1. **Варіант 1. Затримка 5G (N + викиди).** N(5, 1,5²) мс. Знайти P(затримка > 10 мс) — порушення SLA.
2. **Варіант 2. Час від UPS (Exp).** Exp(0,25) год (M=4). Знайти P(X > 6 год).
3. **Варіант 3. Навантаження CPU (N).** N(75, 10²)%. Знайти P(CPU > 90%) — троттлінг, 100 000 вимірів.
4. **Варіант 4. Час відновлення (DR).** RTO = U(1,5) хв + Exp(0,1) хв. Оцінити p95 часу відновлення на 100 000 збоях.
5. **Варіант 5. Смуга CDN (N, 3σ).** N(50, 10²) Мб/с. Перевірити правило 3σ: P(20≤X≤80) на 100 000 сесій.
6. **Варіант 6. Черга Kafka/RabbitMQ (Exp).** Exp(0,5) с. Обчислити p99 та просимулювати 100 000 повідомлень.
7. **Варіант 7. Інференс нейромережі (N).** N(35, 5²) мс. Оцінити P(час > 50 мс, тобто FPS < 20) на 100 000 кадрах.

8. **Варіант 8. Тривалість сесії (Exp).** Exp(0,01) с (M=100). Обчислити p50 і p90 за 100 000 користувачів.

9. **Варіант 9. Build Pipeline (ЦГТ).** 20 кроків по U(10,30) с. За ЦГТ і симуляцією оцінити P(загальний час > 420 с).

Контрольні запитання для самоперевірки та захисту

1. У чому відмінність між функцією розподілу F(x) та щільністю f(x)?
2. Яким властивостям задовольняє f(x)? Чому дорівнює площа під кривою щільності?
3. Як обчислюється M[X] та D[X] для неперервної випадкової величини?
4. Сформулюйте правило трьох сигм для нормального закону.
5. У чому сутність ЦГТ та її значення для інженерії ПЗ?
6. Поясніть інженерний зміст перцентилів затримки p50, p90, p95, p99.