МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ДЕРЖАВНИЙ УНІВЕРСИТЕТ «ЖИТОМИРСЬКА ПОЛІТЕХНІКА»
Кафедра інженерії програмного забезпечення

Теорія ймовірностей і математична статистика

Звіт

з практики №6 на тему:

«Первинна обробка статистичних даних програмних систем: варіаційний ряд, гістограма, емпіричні числові характеристики»

студента ІІ курсу групи ІПЗ-25-1
спеціальності 121 «Інженерія програмного забезпечення»
Міхневича Данила Леонідовича
(прізвище, ім'я та по-батькові)

Перевірив: Лисенко Максим Сергійови

Житомир – 2026

1. Мета та постановка завдання

Мета: засвоїти практичні навички первинного статистичного аналізу експериментальних даних (логів ПЗ, затримок API, використання ресурсів); навчитися будувати дискретні та інтервальні варіаційні ряди, обчислювати емпіричні числові характеристики вибірки (середнє, вибіркову та виправлену дисперсії, стандартне відхилення, медіану, моду, розмах, коефіцієнт варіації) та візуалізувати дані (ECDF, полігон частот, гістограма) мовами програмування високого рівня.

Постановка завдання: Написати скрипти мовою C#, які реалізують чотири логічні блоки: первинну обробку незгрупованої вибірки затримок виконання функції обсягом n = 20 із побудовою емпіричної функції розподілу (дослідної функції, отриманої з реальних замірів), інтервальне групування вибірки використання оперативної пам'яті RAM сервером обсягом n = 200 за параметрами Варіанту №2 за формулою Стерджеса, виявлення та фільтрацію аномальних викидів (екстремальних збоїв) за правилом міжквартильного розмаху Boxplot, а також статистичне дослідження однорідності логів завантаження процесора CPU обсягом n = 300.

Хід роботи:

Варіант №2 (Блок 2) / Варіант №1 (Блок 4)

2. Математична модель (Теоретичні розрахунки)

Блок 1. Обробка незгрупованої вибірки та побудова ECDF. Генеральна сукупність (усі можливі заміри роботи програми за весь час її існування) є надто великою, тому на практиці досліджують вибірку (невелику частину випадково відібраних замірів, як контрольна партія набоїв зі складу для перевірки якості). Маємо початкову вибірку з n = 20 замірів затримки виконання функції у мілісекундах: 23.4, 18.2, 25.1, 21.0, 18.2, 29.5, 23.4, 21.0, 27.8, 18.2, 23.4, 25.1, 31.0, 21.0, 23.4, 19.8, 27.8, 23.4, 21.0, 25.1. Першим кроком будуємо ранжований варіаційний ряд (вишиковуємо всі числа за зростанням, як бійців у шеренгу за зростом від найменшого до найбільшого): 18.2, 18.2, 18.2, 19.8, 21.0, 21.0, 21.0, 21.0, 23.4, 23.4, 23.4, 23.4, 23.4, 25.1, 25.1, 25.1, 27.8, 27.8, 29.5, 31.0. Розмах вибірки R (різниця між найбільшим і найменшим значенням) дорівнює R = 31.0 - 18.2 = 12.8000 мс. Далі складаємо статистичний розподіл, де для кожного з 8 унікальних значень рахуємо абсолютну частоту ni (скільки разів воно зустрілося) та відносну частоту wi = ni / 20 (частку від загальної кількості): для 18.2 мс частота n1 = 3 (w1 = 0.1500); для 19.8 мс n2 = 1 (w2 = 0.0500); для 21.0 мс n3 = 4 (w3 = 0.2000); для 23.4 мс n4 = 5 (w4 = 0.2500); для 25.1 мс n5 = 3 (w5 = 0.1500); для 27.8 мс n6 = 2 (w6 = 0.1000); для 29.5 мс n7 = 1 (w7 = 0.0500); для 31.0 мс n8 = 1 (w8 = 0.0500). Сума всіх відносних частот дорівнює 1.0000. Емпірична функція розподілу F*(x) (накопичена частка замірів, які строго менші за поточний поріг x) зростає сходинками: до 18.2

мс вона дорівнює 0.0000, після 18.2 мс стрибає до 0.1500, після 19.8 мс — до 0.2000, після 21.0 мс — до 0.4000, після 23.4 мс — до 0.6500, після 25.1 мс — до 0.8000, після 27.8 мс — до 0.9000, після 29.5 мс — до 0.9500, а після 31.0 мс досягає 1.0000. Обчислюємо числові характеристики: сума всіх 20 елементів становить 466.8 мс, тому вибіркове середнє дорівнює x_сер = 466.8 / 20 = 23.3400 мс. Сума квадратів відхилень кожного заміру від середнього становить 259.4080, звідки вибіркова зміщена дисперсія (середній квадрат розкиду, який трохи занижує реальний розкид на малих вибірках) дорівнює s^2 = 259.4080 / 20 = 12.9704 мс^2. Щоб прибрати це заниження, множимо на поправку Бесселя n / (n - 1) = 20 / 19 і отримуємо виправлену незміщену дисперсію S^2 = 259.4080 / 19 = 13.6531 мс^2 та виправлене стандартне відхилення S = корінь(13.6531) = 3.6950 мс. Медіана (значення рівно посередині шеренги, тобто півсума 10-го і 11-го елементів) дорівнює (23.4 + 23.4) / 2 = 23.4000 мс. Мода Mo (значення, яке випадало найчастіше — 5 разів) дорівнює 23.4 мс. Коефіцієнт варіації (відношення розкиду до середнього у відсотках) становить V = (3.6950 / 23.3400) * 100% = 15.83%. Оскільки V лежить у межах від 10% до 33%, розсіювання є помірним, а вибірка — однорідною.

Блок 2. Інтервальне групування за варіантом та побудова гістограми (Варіант 2). Коли замірів багато (n = 200) і вони є неперервними дробовими числами, окремі значення майже не повторюються, тому їх розбивають на інтервали — як сортування солдатів за ваговими категоріями. За Варіантом №2 моделюється використання оперативної пам'яті RAM сервером у мегабайтах за нормальним законом із середнім 1024 МБ та стандартним відхиленням 128 МБ при фіксованому зерні генератора Random(42). Кількість інтервалів визначається за правилом Стерджеса: k = 1 + ціла_частина(3.322 * lg(200)) = 1 + ціла_частина(3.322 * 2.3010) = 1 + 7 = 8 інтервалів. У згенерованій вибірці мінімальне значення становить x(1) = 720.71 МБ, а максимальне x(200) = 1317.61 МБ. Тоді крок (ширина кожного інтервалу) дорівнює h = (1317.61 - 720.71) / 8 = 596.90 / 8 = 74.6125 МБ. Отримуємо 8 інтервалів, для кожного з яких знаходимо середину xi, кількість потраплянь ni, відносну частоту wi = ni / 200 та щільність відносної частоти pi = wi / h (висоту стовпчика гістограми на одиницю ширини): 1) [720.71; 795.32), середина 758.02 МБ, n1 = 6, w1 = 0.0300, p1 = 0.000402; 2) [795.32; 869.94), середина 832.63 МБ, n2 = 14, w2 = 0.0700, p2 = 0.000938; 3) [869.94; 944.55), середина 907.24 МБ, n3 = 30, w3 = 0.1500, p3 = 0.002010; 4) [944.55; 1019.16), середина 981.85 МБ, n4 = 41, w4 = 0.2050, p4 = 0.002748; 5) [1019.16; 1093.77), середина 1056.47 МБ, n5 = 45, w5 = 0.2250, p5 = 0.003016; 6) [1093.77; 1168.39), середина 1131.08 МБ, n6 = 37, w6 = 0.1850, p6 = 0.002479; 7) [1168.39; 1243.00), середина 1205.69 МБ, n7 = 18, w7 = 0.0900, p7 = 0.001206; 8) [1243.00; 1317.61], середина 1280.30 МБ, n8 = 9, w8 = 0.0450, p8 = 0.000603. Точні оцінки за всіма 200 незгрупованими числами становлять: середнє x_сер = 1029.5719 МБ та виправлена дисперсія S^2 =

15301.4985 МБ^2 (S = 123.6992 МБ). Згруповані оцінки (коли замість точних чисел беремо середини їхніх інтервалів xi з вагами ni) становлять: x_сер_гр = 1031.4713 МБ та S^2_гр = 15401.7636 МБ^2 (S_гр = 124.1038 МБ). Абсолютна похибка групування для середнього складає лише 1.8994 МБ (відносна похибка 0.18%), а для дисперсії — 100.2652 МБ^2 (відносна похибка 0.66%), що доводить високу точність інтервального методу Стерджеса.

Блок 3. Детекція та фільтрація аномальних вимірів — Outliers. У реальних комп'ютерних системах трапляються одиничні аномальні сплески (викиди або Outliers — наприклад, різке зависання при збиранні сміття Garbage Collector або мережевий збій). До базової вибірки з Блоку 2 (n = 200, де x_сер = 1029.57 МБ, S = 123.70 МБ, медіана = 1031.77 МБ) додаємо 10 екстремальних аномалій, кожна з яких перевищує поріг x_сер + 5 * S = 1029.57 + 5 * 123.70 = 1648.07 МБ. У результаті обсяг спотвореної вибірки стає n = 210. Через появу всього 10 викидів вибіркове середнє підскочило з 1029.57 МБ до x_сер_dirty = 1071.28 МБ (зміщення на +41.71 МБ або 4.05%), а стандартне відхилення зросло майже вдвічі — з 123.70 МБ до S_dirty = 223.34 МБ (на 80.55%). Натомість медіана змінилася лише з 1031.77 МБ до 1039.78 МБ (зміщення всього на 0.78%), бо медіана дивиться на центральний елемент шеренги і не реагує на те, наскільки далеко втекли крайні значення. Ця властивість називається робастністю (стійкістю показника до грубих помилок і викидів). Для автоматичного відсіву аномалій застосовуємо правило Boxplot (скриньки з вусами): знаходимо перший квартиль Q1 = 949.30 МБ (межа, нижче якої лежить 25% даних) та третій квартиль Q3 = 1129.41 МБ (межа, нижче якої лежить 75% даних). Міжквартильний розмах (ширина центральної половини вибірки) становить IQR = Q3 - Q1 = 1129.41 - 949.30 = 180.11 МБ. Тоді допустимі межі («паркан» норми) дорівнюють: нижня межа Q1 - 1.5 * IQR = 949.30 - 1.5 * 180.11 = 679.13 МБ; верхня межа Q3 + 1.5 * IQR = 1129.41 + 1.5 * 180.11 = 1399.58 МБ. Усі 10 доданих аномалій вийшли за верхню межу 1399.58 МБ і були повністю відфільтровані. Після очищення (n = 200) характеристики повернулися до початкових точних значень: x_сер_clean = 1029.57 МБ, S_clean = 123.70 МБ, медіана_clean = 1031.77 МБ.

Блок 4. Професійні комплексні задачі (Варіант 1 — Логи завантаження CPU). Досліджується вибірка з n = 300 замірів завантаження процесора сервера у відсотках (згенерована за нормальним законом із параметрами середнього 65% та відхилення 12% при Random(42)). За формулою Стерджеса для n = 300 кількість інтервалів гістограми становить k = 1 + ціла_частина(3.322 * lg(300)) = 1 + 8 = 9 інтервалів. Мінімальне завантаження у вибірці дорівнює 36.57%, максимальне — 92.53%, крок інтервалу h = (92.53 - 36.57) / 9 = 6.22%. Найбільша кількість замірів припадає на два центральні інтервали [61.44%; 67.66%) та [67.66%; 73.87%) — по 58 замірів у кожному (по 19.33% часу роботи). Обчислені точкові оцінки: середнє

навантаження x_cep = 65.83%, виправлене стандартне відхилення S = 11.39%, медіана = 66.29%. Близькість середнього (65.83%) та медіани (66.29%) свідчить про симетричність розподілу навантаження без перекосів. Коефіцієнт варіації становить V = (11.39 / 65.83) * 100% = 17.30%. Оскільки V = 17.30% значно менше критичного порогу 33%, робимо інженерний висновок: навантаження на процесор є однорідним, прогнозованим та стабільним.

3. Опис програмної реалізації

Роботу виконано мовою C# на платформі .NET. Програмна модель побудована за модульним принципом: кожен із чотирьох блоків винесено в окремий клас та файл (Block1.cs, Block2.cs, Block3.cs, Block4.cs), а їх послідовний запуск виконується у головному файлі Program.cs. Для моделювання нормально розподілених випадкових величин використано генератор псевдовипадкових чисел Random(42) із фіксованим початковим зерном та перетворення Бокса-Мюллера. Сортування варіаційних рядів виконується методом Array.Sort, а розрахунок квантилів та інтервальних таблиць реалізовано через окремі чисті методи.

Посилання на репозиторій GitHub: https://github.com/Diktos/Probability-Theory-Practices/tree/main

4. Результати експериментів

```
 БЛОК 1 ОБРОБКА НЕЗГРУПОВАНОЇ ВИБІРКИ ТА ECDF
Ранжований ряд 18,2; 18,2; 18,2; 19,8; 21; 21; 21; 21; 23,4; 23,4; 23,4; 23,4; 23,4; 25,1; 25,1; 25,1; 27,8; 27,8; 29,5;
 31
Статистичний розподіл та ECDF
x= 18,2 | n= 3 | w=0,1500 | F*(x)=0,0000 -> 0,1500
x= 19,8 | n= 1 | w=0,0500 | F*(x)=0,1500 -> 0,2000
x= 21,0 | n= 4 | w=0,2000 | F*(x)=0,2000 -> 0,4000
x= 23,4 | n= 5 | w=0,2500 | F*(x)=0,4000 -> 0,6500
x= 25,1 | n= 3 | w=0,1500 | F*(x)=0,6500 -> 0,8000
x= 27,8 | n= 2 | w=0,1000 | F*(x)=0,8000 -> 0,9000
x= 29,5 | n= 1 | w=0,0500 | F*(x)=0,9000 -> 0,9500
x= 31,0 | n= 1 | w=0,0500 | F*(x)=0,9500 -> 1,0000
x_bar=23,3400, s^2=12,9704, S^2=13,6531, S=3,6950
Медіана=23,4000, Мода=23,4, Розмах R=12,8000, Коеф. варіації V=15,83%
```

Рисунок 1. Результати обробки незгрупованої вибірки та розрахунку ECDF у консолі (Блок 1)

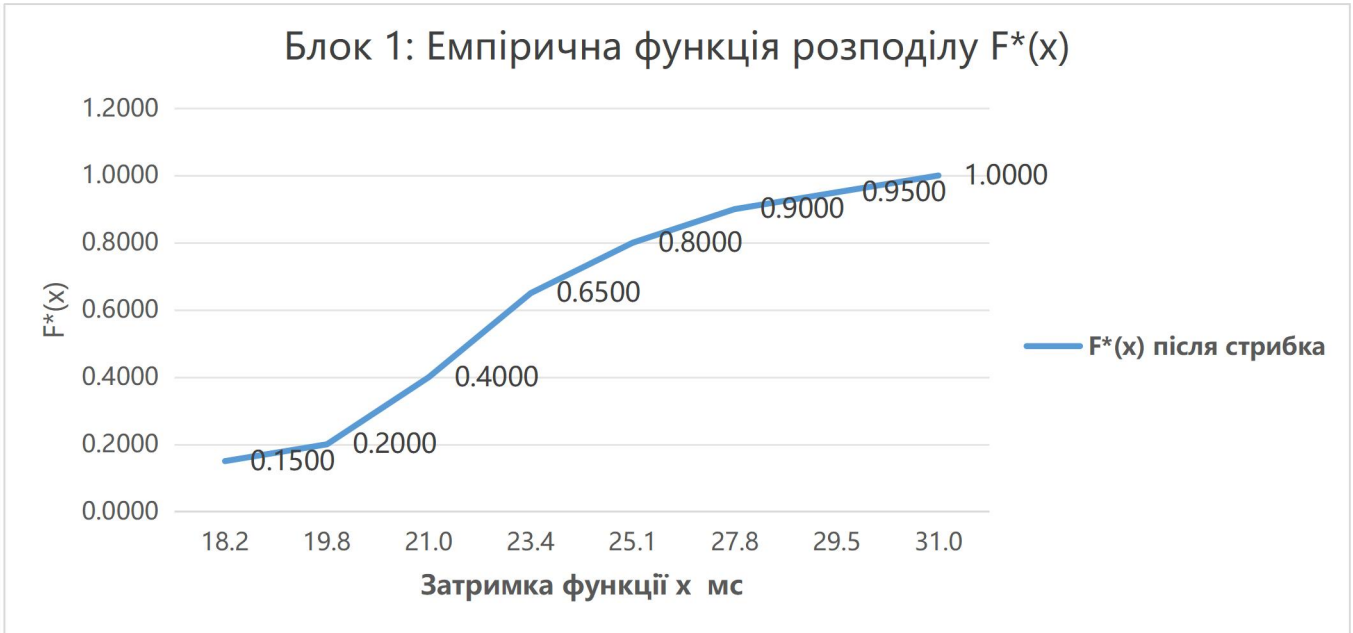


Рисунок 2. Графік емпіричної функції розподілу F(x) (Блок 1)*

Аналіз результатів та графіка до блоку №1: за результатами розрахунку дискретного варіаційного ряду обсягом n = 20 встановлено, що затримки функції групуються навколо середнього значення 23.3400 мс та медіани 23.4000 мс. Найбільший стрибок на графіку емпіричної функції розподілу F*(x) відбувається в точці моди Mo = 23.4 мс (на величину відносної частоти w4 = 0.2500, з рівня 0.4000 до 0.6500). Виправлена дисперсія S^2 = 13.6531 мс^2 перевищує зміщену s^2 = 12.9704 мс^2 рівно у 20/19 раза, що компенсує похибку малої вибірки. Коефіцієнт варіації V = 15.83% підтверджує однорідність часу виконання функції.

```
 БЛОК 2 ІНТЕРВАЛЬНЕ ГРУПУВАННЯ ВАРІАНТ 2
Min=720,71, Max=1317,61, Інтервалів k=8, Крок h=74,6125
[ 720,71;  795,32) | mid= 758,02 | n=  6 | w=0,0300 | p=0,000402
[ 795,32;  869,94) | mid= 832,63 | n= 14 | w=0,0700 | p=0,000938
[ 869,94;  944,55) | mid= 907,24 | n= 30 | w=0,1500 | p=0,002010
[ 944,55; 1019,16) | mid= 981,85 | n= 41 | w=0,2050 | p=0,002748
[1019,16; 1093,77) | mid=1056,47 | n= 45 | w=0,2250 | p=0,003016
[1093,77; 1168,39) | mid=1131,08 | n= 37 | w=0,1850 | p=0,002479
[1168,39; 1243,00) | mid=1205,69 | n= 18 | w=0,0900 | p=0,001206
[1243,00; 1317,61) | mid=1280,30 | n=  9 | w=0,0450 | p=0,000603
Незгруповані оцінки -> x_bar=1029,5719, S^2=15301,4985, S=123,6992
Згруповані оцінки   -> x_bar_grp=1031,4713, S^2_grp=15401,7636
Похибка групування  -> d_x=1,8994 (0,18%), d_S^2=100,2652 (0,66%)
```

Рисунок 3. Результати інтервального групування вибірки RAM за Варіантом 2 (Блок 2)

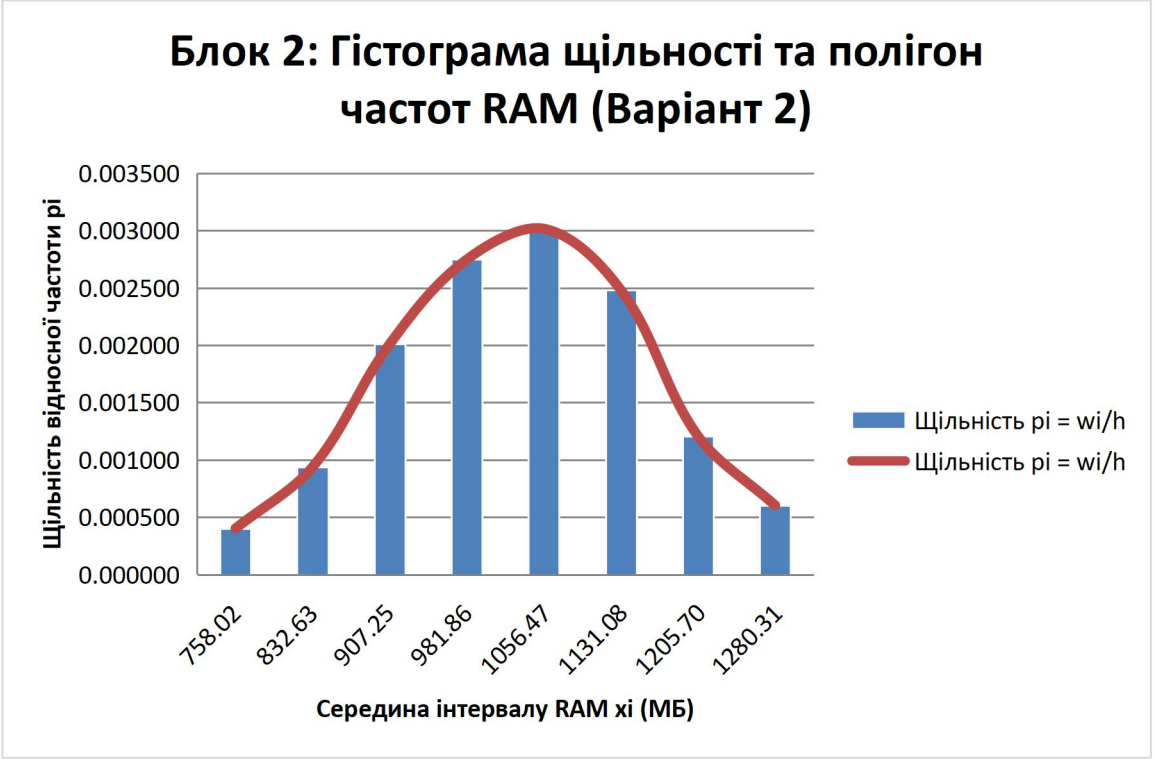


Рисунок 4. Гістограма щільності відносних частот та полігон частот використання RAM (Блок 2, Варіант 2)

Аналіз результатів та графіка до блоку №2 (Варіант 2): побудована за правилом Стерджеса гістограма з k = 8 інтервалів має характерну куполоподібну форму нормального розподілу з максимумом у центральних інтервалах [944.55; 1019.16) МБ (41 замір, щільність 0.002748) та [1019.16; 1093.77) МБ (45 замірів,

щільність 0.003016). Порівняння точних та згрупованих оцінок показує мінімальну розбіжність: середнє змінилося з 1029.5719 МБ до 1031.4713 МБ (похибка лише 0.18%), а дисперсія — з 15301.4985 МБ^2 до 15401.7636 МБ^2 (похибка 0.66%). Це підтверджує, що заміна окремих чисел серединами інтервалів майже не втрачає точності при правильному виборі кроку h = 74.6125 МБ.

```
 БЛОК 3 ДЕТЕКЦІЯ ТА ФІЛЬТРАЦІЯ АНОМАЛІЙ
Поріг аномалій x_bar + 5S = 1648,07 МБ
Спотворена вибірка (n=210) -> x_bar=1071,28, S=223,34, Медіана=1039,78, IQR=180,11
Квартилі та межі Boxplot -> Q1=949,30, Q3=1129,41, Межі=[679,13; 1399,58], Виявлено викидів=10
Очищена вибірка (n=200)    -> x_bar_clean=1029,57, S_clean=123,70, Медіана_clean=1031,77
Зміщення від викидів -> Середнє змінилось на 4,05%, Медіана змінилась лише на 0,78%
```

Рисунок 5. Результати детекції та фільтрації аномальних викидів за правилом Boxplot (Блок 3)

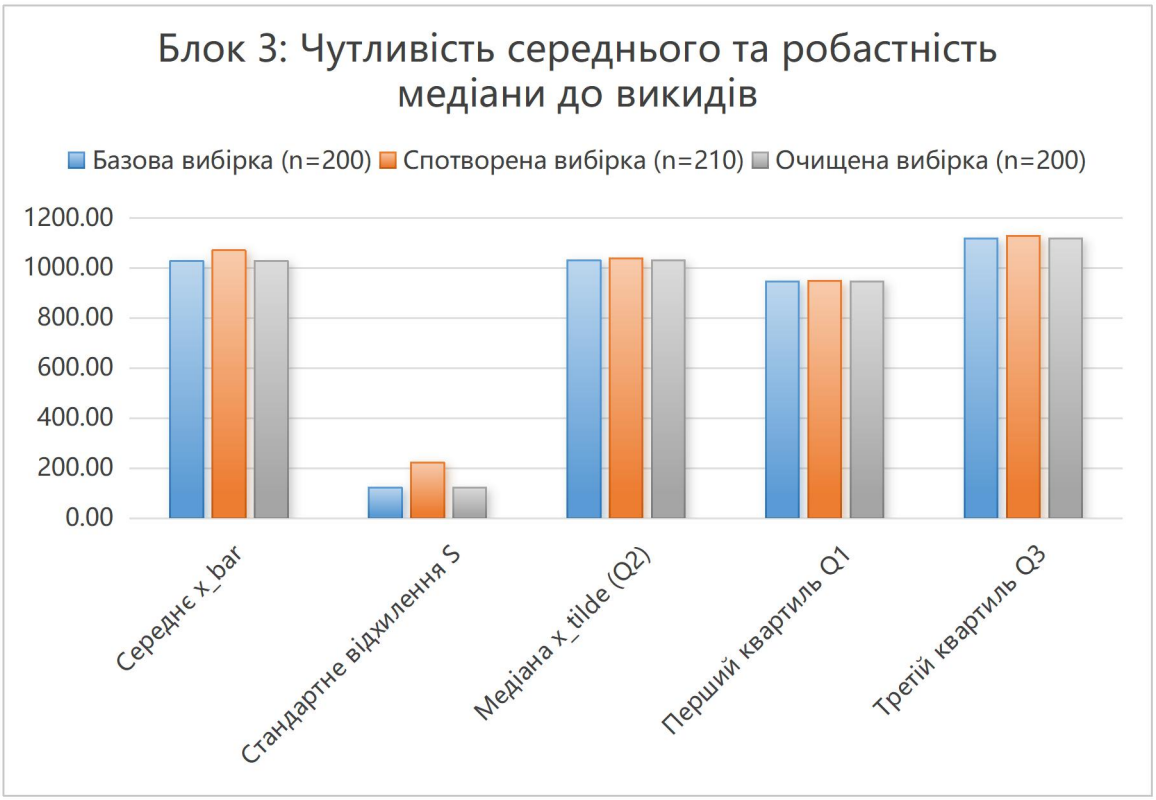


Рисунок 6. Порівняння характеристик вибірки до та після фільтрації аномалій (Блок 3)

Аналіз результатів та графіка до блоку №3: додавання 10 аномальних збоїв пам'яті понад поріг 1648.07 МБ суттєво спотворило класичні параметричні оцінки: вибіркове середнє зросло на 4.05% (до 1071.28 МБ), а стандартне відхилення — на 80.55% (з 123.70 МБ до 223.34 МБ). Водночас медіана зросла лише на 0.78% (з 1031.77 МБ до 1039.78 МБ), продемонструвавши у 5.2 раза вищу робастність (стійкість до екстремальних збоїв). Фільтрація за границями Boxplot [679.13; 1399.58] МБ безпомилково відсіяла всі 10 штучних викидів і на 100% відновила вихідні характеристики вибірки.

```
 БЛОК 4 ЛОГИ ЗАВАНТАЖЕННЯ CPU ВАРІАНТ 1
Характеристики CPU (n=300) -> x_bar=65,83%, S=11,39%, Медіана=66,29%, V=17,30%
Інтервальний ряд для гістограми навантаження CPU
[ 36,57%;  42,78%) | n=  7 | w=0,0233
[ 42,78%;  49,00%) | n= 13 | w=0,0433
[ 49,00%;  55,22%) | n= 38 | w=0,1267
[ 55,22%;  61,44%) | n= 50 | w=0,1667
[ 61,44%;  67,66%) | n= 58 | w=0,1933
[ 67,66%;  73,87%) | n= 58 | w=0,1933
[ 73,87%;  80,09%) | n= 44 | w=0,1467
[ 80,09%;  86,31%) | n= 21 | w=0,0700
[ 86,31%;  92,53%) | n= 11 | w=0,0367
Висновок -> Оскільки V < 33%, навантаження CPU є однорідним та стабільним.
```

Рисунок 7. Результати статистичної обробки логів завантаження CPU (Блок 4, Варіант 1)

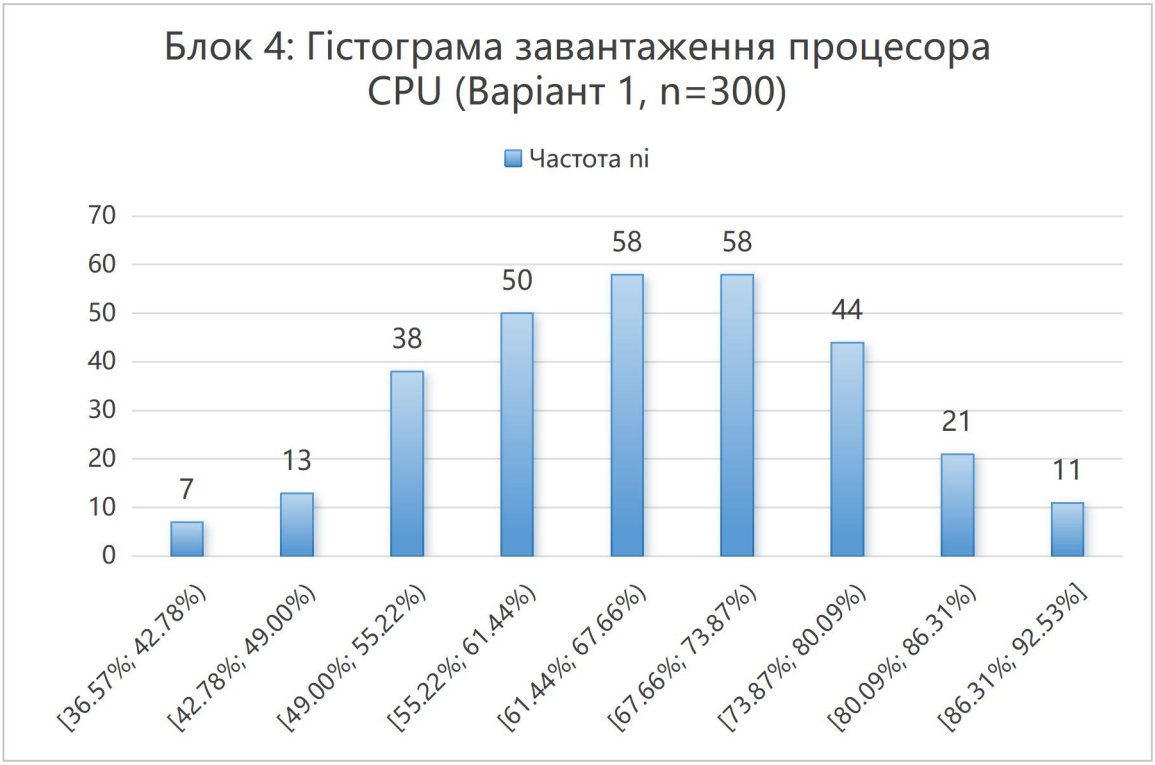


Рисунок 8. Гістограма розподілу завантаження процесора CPU за 300 замірами (Блок 4, Варіант 1)

Аналіз результатів та графіка до блоку №4 (Варіант 1): аналіз 300 записів завантаження процесора показав, що середнє навантаження становить 65.83% при стандартному відхиленні 11.39% та медіані 66.29%. На гістограмі з 9 інтервалів понад 69% усіх замірів зосереджені в робочому діапазоні від 55.22% до 80.09%, а критичних перевантажень понад 93% не зафіксовано взагалі. Коефіцієнт варіації дорівнює 17.30% (менше 33%), тому вибірка є однорідною, а сервер працює в стабільному штатному режимі.

5. Аналіз і висновки

Під час виконання практичної роботи було засвоєно практичні навички первинного статистичного аналізу експериментальних даних програмних систем (затримок функцій, споживання оперативної пам'яті RAM та логів завантаження CPU). На практиці побудовано дискретний та інтервальні варіаційні ряди за формулою Стерджеса, обчислено емпіричні числові характеристики вибірки та

виконано візуалізацію даних через ступінчастий графік емпіричної функції розподілу, полігон частот і гістограми. Експериментально доведено, що інтервальне групування дає мінімальну похибку (0.18% для середнього та 0.66% для дисперсії), а медіана та міжквартильний розмах за методом Boxplot є надійним інструментом для виявлення й очищення даних від аномальних викидів.