ПРАКТИЧНА РОБОТА № 11-12

Первинна обробка статистичних даних програмних систем: варіаційний ряд, гістограма, емпіричні числові характеристики

Мета: засвоїти практичні навички первинного статистичного аналізу експериментальних даних (логів ПЗ, затримок API, використання ресурсів); навчитися будувати дискретні та інтервальні варіаційні ряди, обчислювати емпіричні числові характеристики вибірки (середнє, вибіркову та виправлену дисперсії, стандартне відхилення, медіану, моду, розмах, коефіцієнт варіації) та візуалізувати дані (ECDF, полігон частот, гістограма) мовами програмування високого рівня.

Компетентності, що формуються:

– розуміння зв’язку між генеральною сукупністю та вибіркою, вимог до репрезентативності;

– вміння групувати дані, застосовувати формулу Стерджеса та обчислювати точкові статистичні оцінки;

– вміння використовувати numpy, scipy.stats, pandas, matplotlib, seaborn для обробки та візуалізації вибірки.

–

Прив’язка блоків до теми «Первинна обробка вибірки»

Блок	Теоретична основа	Тема
Блок 1 — Обробка незгрупованої вибірки та ECDF	Генеральна сукупність і вибірка, ранжований варіаційний ряд, емпірична функція $F^*_n(x)$	Лекція 6
Блок 2 — Інтервальне групування за варіантом	Формула Стерджеса, інтервальний ряд, полігон частот, гістограма, згруповані оцінки	Лекція 6
Блок 3 — Детекція та фільтрація аномалій (Outliers)	Квартилі Q_1, Q_3, міжквартильний розмах IQR, правило Boxplot, порівняння оцінок	Лекція 6
Блок 4 — Професійні комплексні задачі	Статистична обробка логів CPU/RAM, часу рендерингу, тривалості тестів, затримок	Лекція 6

Короткі теоретичні відомості

1. Вибірка та варіаційний ряд

Генеральна сукупність — множина всіх можливих результатів (обсяг N). Вибірка — **n** випадково відібраних елементів. Ранжований варіаційний ряд: $x_{(1)} \le x_{(2)} \le \ldots \le x_{(n)}$. Розмах: $R = x_{(n)} - x_{(1)}$.

2. Інтервальне групування та формула Стерджеса

$$k = 1 + \log_2 n \approx 1 + 3{,}322 \cdot \log_{10} n, \quad h = (x_{(n)} - x_{(1)}) / k$$

3. Емпірична функція розподілу (ECDF)

$$F^*_n(x) = n_x / n$$

де n_x — кількість елементів вибірки, строго менших за x.

4. Емпіричні числові характеристики вибірки

$$\bar{x} = (1/n)\Sigma x_i \; ; \quad s^2 = (1/n)\Sigma(x_i - \bar{x})^2 \; ; \quad S^2 = (n/(n-1)) \cdot s^2 \; ; \quad S = \sqrt{S^2}$$

– Медіана $\tilde{x}$ — значення, що ділить ряд навпіл (для парного n — півсума двох центральних);

– Мода M_o — найчастіший елемент вибірки;

– Коефіцієнт варіації $V = (S/\bar{x}) \cdot 100\%$: V < 10% — розсіювання незначне; V > 33% — вибірка неоднорідна.

Структура практичного завдання

Робота складається з чотирьох обов’язкових блоків.

Блок 1. Обробка незгрупованої вибірки та побудова ECDF

Провести первинний аналіз вибірки обсягом **n = 20** (затримки виконання функції, мс):

```
X_raw = [23.4, 18.2, 25.1, 21.0, 18.2, 29.5, 23.4, 21.0, 27.8, 18.2,
         23.4, 25.1, 31.0, 21.0, 23.4, 19.8, 27.8, 23.4, 21.0, 25.1]
```

Завдання:

1. Побудувати ранжований варіаційний ряд.
2. Скласти статистичний розподіл: унікальні значення x_i, абсолютні частоти n_i, відносні $w_i = n_i/n$.

3. Обчислити $\bar{x}$; вибіркову s^2 та виправлену S^2 дисперсії; виправлене S; медіану $\tilde{x}$, моду M_o, розмах R, коефіцієнт варіації V.

4. Побудувати ступінчастий графік емпіричної функції розподілу $F^*_n(x)$.

Блок 2. Інтервальне групування за варіантом та побудова гістограми

Провести інтервальне групування великої вибірки **n = 200** за своїм варіантом. Вибір варіанта: **Variant = (Nстудента mod 6) + 1**. Фіксувати np.random.seed(42).

Параметри симуляції вибірки (n = 200) за варіантами

Варіант 1. Затримка мікросервісу A (ms): $N(\mu=150, \sigma^2=20^2)$ + 5% сплесків U(200, 300).

Варіант 2. Використання RAM сервером (MB): $N(\mu=1024, \sigma^2=128^2)$.

Варіант 3. Тривалість сесії (сек): Exp(λ=0,02), M[X]=50 сек.

Варіант 4. Пропускна здатність адаптера (Mbps): U(a=50, b=450).

Варіант 5. Розмір JSON-відповідей REST API (KB): логнормальний, μ=3,0, σ=0,5.

Варіант 6. Час у черзі RabbitMQ (ms): суміш U(10,50) (80%) та Exp(0,01) (20%).

Порядок виконання:

1. Згенерувати вибірку n = 200 згідно з варіантом.

2. Обчислити число інтервалів за Стерджесом: $k = 1 + \lfloor 3{,}322 \cdot \log_{10}(200) \rfloor = 1 + 7 = 8$.

3. Обчислити крок $h = (x_{(200)} - x_{(1)})/8$ і побудувати інтервальний ряд: межі $[a_i, a_{i+1})$, середини x_i, частоти n_i, відносні w_i, щільності $p_i = w_i/h$.

4. Обчислити згруповані оцінки: $\bar{x}_grp = (1/n)\Sigma n_i x_i$, $S^2_grp = (1/(n-1))\Sigma n_i (x_i - \bar{x}_grp)^2$.

5. Побудувати гістограму щільності відносних частот та полігон частот на одному рисунку.

6. Порівняти незгруповані ($\bar{x}$, S^2) та згруповані ($\bar{x}_grp$, S^2_grp) оцінки, оцінити похибку групування.

Блок 3. Детекція та фільтрація аномальних вимірів — Outliers

Статистичний аналіз даних із викидами (мережеві збої, паузи Garbage Collector).

Завдання:

1. До вибірки з Блоку 2 (n = 200) додати 10 аномальних значень, що перевищують $\bar{x} + 5S$.
2. Обчислити характеристики спотвореної вибірки: $\bar{x}$_dirty, S_dirty, $\tilde{x}$_dirty, IQR_dirty.
3. Побудувати Boxplot та ідентифікувати викиди: Q_1 (25-й перцентиль), Q_3 (75-й), $IQR = Q_3 - Q_1$, межі $[Q_1 - 1{,}5 \cdot IQR;\ Q_3 + 1{,}5 \cdot IQR]$.
4. Відфільтрувати викиди, обчислити очищені $\bar{x}$_clean, S_clean, $\tilde{x}$_clean.
5. Проаналізувати робастність медіани $\tilde{x}$ порівняно із середнім $\bar{x}$ за наявності викидів.

Блок 4. Професійні комплексні задачі

Варіант 1. Логи завантаження CPU. n=300 замірів. Гістограма, $\bar{x}$, S, $\tilde{x}$, V; висновок про однорідність навантаження.

Варіант 2. Швидкодія двох версій алгоритму. Дві вибірки по n=100 (A до / B після рефакторингу). Суміщені полігони, $\bar{x}$_A, $\bar{x}$_B, S_A, S_B; оцінка зміни середнього й стабільності.

Варіант 3. Розмір пакетів у дампі. n=500 з pcap. Інтервальний ряд, ECDF, мода M_o, медіана $\tilde{x}$; оцінка мультимодальності.

Варіант 4. Час реакції UI. n=150. Квартилі Q_1, $Q_2(\tilde{x})$, Q_3, Boxplot; частка затримок за межами 100 мс.

Варіант 5. Тривалість юніт-тестів CI/CD. n=250. Гістограма; виявити «повільні» тести ($Q_3 + 1{,}5 \cdot IQR$), S^2 до і після видалення.

Варіант 6. Виділення пам'яті в JVM (GC). n=180. $\bar{x}$, S, V; гістограма; перевірка симетрії за відношенням середнє/медіана.

Варіант 7. Затримки читання SSD/HDD. n=200. Варіаційний ряд, розмах R, $\bar{x}$; оцінка асиметрії вибірки.

Варіант 8. Лічильники контейнерів Docker. n=300. Інтервальний розподіл за Стерджесом, полігон частот; частка інтервалів із піковим навантаженням.

Варіант 9. Час обробки запитів БД. n=400. ECDF і гістограма, $\bar{x}$, S^2, S; виявлення аномалій за IQR; середнє до і після очищення.

Контрольні запитання для самоперевірки та захисту

1. Чим відрізняється генеральна сукупність від вибірки? Яка вибірка репрезентативна?
2. Що таке варіаційний ряд? Які види (дискретний, інтервальний) ви знаєте?
3. За якою формулою визначають кількість інтервалів (метод Стерджеса)?
4. Назвіть властивості емпіричної функції $F^*_n(x)$. Чим вона відрізняється від теоретичної F(x)?
5. У чому різниця між s^2 та виправленою S^2? Чому s^2 — зміщена оцінка?
6. Поясніть детекцію викидів за IQR та Boxplot. Чому медіана робастніша за середнє?